Recuperación de imágenes

SIFT, BoVW, VLAD y re-ranking sobre Oxford Buildings y Paris Buildings

Diego Quispe Brigitte Rojas Alvaro Garcia Sofia Salazar Marcelino Maita

Visión por Computador
Proyecto 1

21 de septiembre de 2026

Índice

1. Problema y dataset
2. Pipeline general
3. BoVW: vocabulario, histograma y distancias
4. VLAD y vocabulario visual
5. Comparativa de representaciones
6. Mejoras progresivas sobre VLAD
7. Evaluación
8. Oxford vs. Paris
9. Casos exitosos y de fallo

Problema y dataset

Oxford Buildings

- 5,062 imágenes
- 11 landmarks, 55 queries

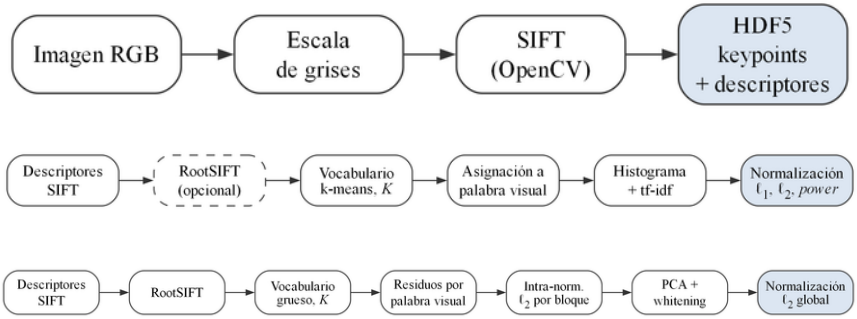
Paris Buildings

- 6,412 imágenes
- 11 landmarks, 55 queries

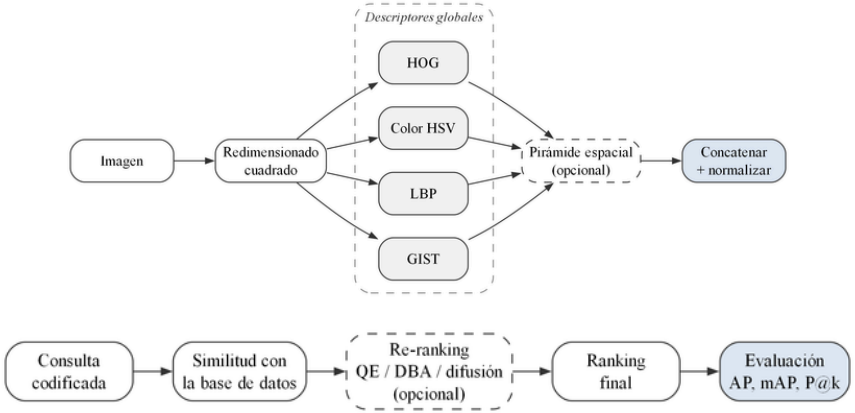
Cada query tiene imagen, bounding box y listas good, ok y junk.



Pipeline general (1/2): extracción de descriptores



Pipeline general (2/2): descriptores globales y ranking

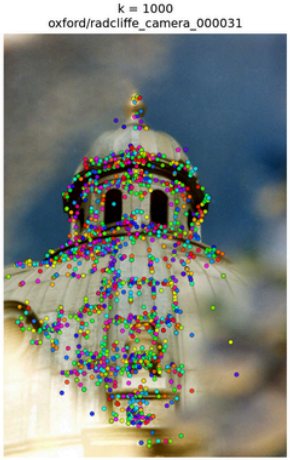


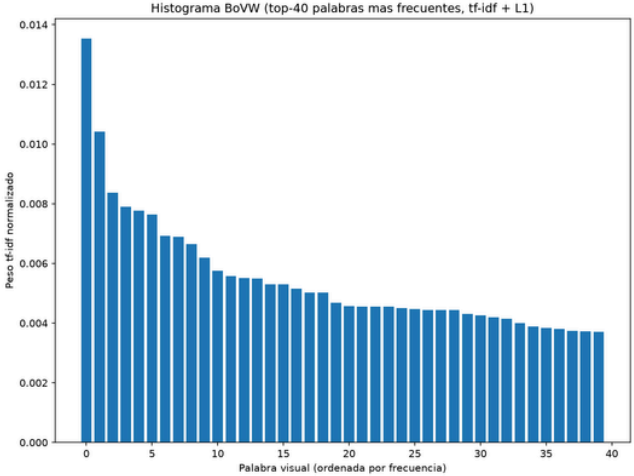
Descriptores globales

- Describen la imagen con un vector de largo fijo sin depender de keypoints
- HOG resume la distribución de direcciones de los bordes, LBP la textura, HSV el color y GIST la envolvente espacial.
- Un cambio de punto de vista altera el descriptor completo, por eso no llegan ni a 0.17 mAP

Descriptor	Oxford5k	Paris6k
HOG	0,1467	0,1504
GIST	0,1427	0,1338
LBP	0,1072	0,0847
Color	0,1049	0,0913
Combinado + PCA512	0,1644	0,1409

BoVW e histograma en una imagen





BoVW : normalización y métrica (K = 1000)

La métrica óptima depende del dataset. En Oxford5k gana la intersección de histogramas sin normalizar (0,2871) y en Paris6k gana el coseno (0,3097 frente a 0,2848 de la intersección). La intersección compara la masa compartida y el coseno compara el ángulo, así que el cambio de ganador indica que la distribución de palabras visuales difiere entre datasets

Oxford5k

Norm.	cos	ℓ_2	χ^2	Hell.	Inter.
ninguna	0,2783	0,2475	0,2815	0,2599	0,2871
ℓ_1	0,2783	0,2475	0,2815	0,2599	0,2871
ℓ_2	0,2783	0,2782	0,2857	0,2599	0,1357
power	0,2599	0,2599	0,2135	0,1552	0,1333
Hellinger	0,2599	0,2599	0,2135	0,1552	0,1333

Paris6k

Norm.	cos	ℓ_2	χ^2	Hell.	Inter.
ninguna	0,3097	0,2547	0,2746	0,2515	0,2848
ℓ_1	0,3097	0,2547	0,2746	0,2515	0,2848
ℓ_2	0,3097	0,3097	0,2877	0,2515	0,1505
power	0,2515	0,2515	0,1850	0,1367	0,1217
Hellinger	0,2515	0,2515	0,1850	0,1367	0,1217

Mejoras progresivas sobre VLAD

Base: similitud coseno entre vectores normalizados.

- QE y DBA reutilizan los vecinos inmediatos de la consulta.
- La difusión propaga similitud por todo el grafo k-NN de la base y alcanza positivos separados de la consulta por varios saltos.

Configuración	Oxford5k	Paris6k
VLAD ($K = 256$, PCA512)	0,5282	0,5514
+ Query Expansion (top-10)	0,5545	0,5813
+ DBA ($n = 5$)	0,5817	0,6125
+ DBA(3) + QE(10)	0,5945	0,6278
+ Difusión ($k = 50$, sin DBA)	0,6780	0,8105
+ DBA(5) + Dif.(k=100, 5 sem.)	0,7053	0,8119

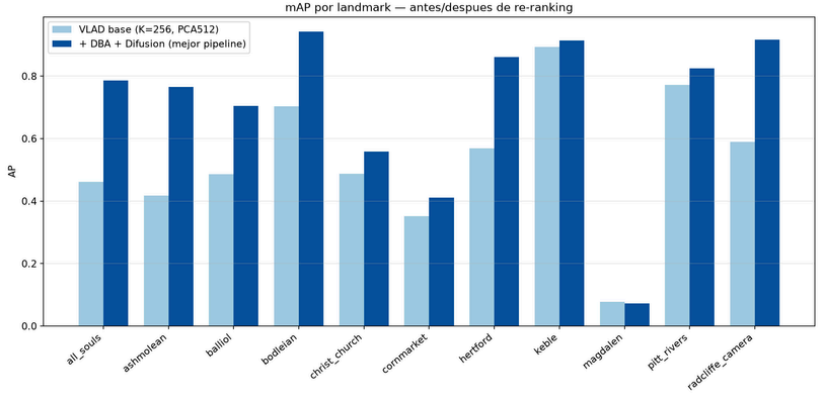
Comparación de representaciones: Oxford5k y Paris6k

Paris6k supera a Oxford5k en 7 de las 9 representaciones. Que el orden se repita en dos colecciones distintas respalda que nuestro pipeline final es robusto.

Representación	Oxford5k			Paris6k		
	mAP	P@5	P@10	mAP	P@5	P@10
VLAD + DBA + Difusión (final)	0,7053	0,8436	0,7509	0,8119	0,9855	0,9909
Fusión (VLAD + global)	0,5337	0,8364	0,6945	0,5585	0,9927	0,9782
VLAD ($K = 256$, PCA512)	0,5282	0,8364	0,6891	0,5514	0,9855	0,9673
BoVW ($K = 4096$)	0,3136	0,6436	0,5145	0,3641	0,8291	0,7527
Combinado global (PCA512, w=0, 5)	0,1644	0,4764	0,3564	0,1409	0,6945	0,5618
HOG	0,1467	0,4582	0,3182	0,1504	0,6873	0,5782
GIST	0,1427	0,4400	0,3127	0,1338	0,6764	0,5418
LBP	0,1072	0,3018	0,1909	0,0847	0,4655	0,3382
Color	0,1049	0,3055	0,1982	0,0913	0,4982	0,3582

Dónde falla el modelo final

Tras el re-ranking, los AP de todos los landmarks mejoraron, excepto magdalen. Esto indica que el problema está en las propias imágenes relevantes y no en la etapa de ranking.



Caso exitoso Paris: (AP = 0,9940)



Caso exitoso Oxford: (AP = 0,9752)

QUERY
bodleian_000107



#1 query
bodleian_000107



#2 ok
bodleian_000298



#3 ok
bodleian_000381



#4 ok
bodleian_000108



#5 ok
bodleian_000208



Caso de fallos Paris: (AP = 0,2306)

La Torre Eiffel se fotografía desde ángulos, distancias e iluminaciones mucho más heterogéneos que una fachada de museo, así que sus propias consultas tienen menos similitud visual entre sí



Caso de fallo Oxford: (AP = 0,0220)

La torre está ocluida por árboles y el sistema recupera otras escenas con vegetación de estructura similar.













Gracias

Referencias

[1] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” International Journal of Computer Vision, vol. 60, no. 2, pp. 91–110, 2004.
[2] G. Csurka, C. Dance, L. Fan, J. Willamowski, and C. Bray, “Visual categorization with bags of keypoints,” in Workshop on Statistical Learning in Computer Vision, ECCV, 2004.
[3] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2005.
[4] R. Arandjelovic and A. Zisserman, “Three things everyone should know to improve object retrieval,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2911–2918, 2012.
[5] R. Arandjelović and A. Zisserman, “All about VLAD,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1578–1585, 2013.
[6] H. Jégou, M. Douze, C. Schmid, and P. Pérez, “Aggregating local descriptors into a compact image representation,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 3304–3311, 2010.
[7] H. Jégou and O. Chum, “Negative evidences and co-occurrences in image retrieval: The benefit of PCA and whitening,” in Proceedings of the European Conference on Computer Vision (ECCV), pp. 155–168, Springer, 2012.
[8] J. Philbin, O. Chum, M. Isard, J. Sivic, and A. Zisserman, “Object retrieval with large vocabularies and fast spatial matching,” in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2007.